

江苏大学课程报告



SPARTA-Net：基于场景感知生成对抗网络的 Radio Map 补全方法

学 号： 3240601042

班 级： 通信 2402

姓 名： 徐奕博

报 告 类 型： 智能通信技术基础期末任务

2025 年 11 月

摘 要

Radio Map 作为反映不同物理位置接收信号强度的无线电地图，在现代无线通信系统中具有重要应用价值。本文针对 Radio Map 补全任务，提出了一种基于场景感知生成对抗网络的 SPARTA-Net (Spatially-aware Pattern-Adaptive Radio Topology Architecture) 架构。通过深入分析数据集特性，发现训练集与测试集共享相同的 701 个地图场景，仅基站位置不同，这一关键观察促使我们重新定义了问题本质——从通用的图像修复任务转化为特定场景下的基站位置泛化问题。SPARTA-Net 通过引入地图嵌入 (Map Embedding) 和基站嵌入 (BS Embedding) 机制，为每个地图场景学习独特的特征表示，同时建模基站位置的空间关系。实验结果表明，相比传统方法 RadioUNet、RME-GAN 以及空间频域混合方法，在测试集上，SPARTA-Net 将归一化均方误差 (NMSE) 从 5×10^{-5} 降低至 1.3×10^{-5} ，性能提升约 4 倍。本研究不仅在技术层面实现了突破，更重要的是提供了一种新的问题建模视角，即将 Radio Map 补全视为条件生成问题，其中场景和位置信息作为关键条件输入。

关键词：Radio Map 补全；场景感知；生成对抗网络；深度学习；无线通信

Abstract

Radio Map, which reflects the received signal strength at different physical locations, plays a crucial role in modern wireless communication systems. This paper proposes SPARTA-Net (Spatially-aware Pattern-Adaptive Radio Topology Architecture), a scene-aware generative adversarial network architecture for Radio Map completion tasks. Through in-depth analysis of dataset characteristics, we discovered that the training and test sets share the same 701 map scenarios with different base station positions, leading us to redefine the problem from general image inpainting to base station position generalization in specific scenarios. SPARTA-Net introduces Map Embedding and BS Embedding mechanisms to learn unique feature representations for each map scenario while modeling spatial relationships of base station positions. Experimental results demonstrate that compared to traditional methods including RadioUNet, RME-GAN, and spatial-frequency hybrid approaches, SPARTA-Net reduces the Normalized Mean Square Error (NMSE) from 5×10^{-5} to 1.3×10^{-5} on test set, achieving approximately 4-fold performance improvement. This research not only achieves technical breakthroughs but also provides a novel problem modeling perspective, treating Radio Map completion as a conditional generation problem where scene and location information serve as key conditional inputs.

Keywords: Radio Map Completion; Scene-Aware; Generative Adversarial Network; Deep Learning; Wireless Communication

目录

1	引言	1
1.1	研究背景与意义	1
1.2	研究动机	1
1.3	主要贡献	1
2	相关工作	2
2.1	传统 Radio Map 估计方法	2
2.2	深度学习方法的兴起	2
2.3	生成模型在 Radio Map 补全中的应用	2
2.4	图像修复技术的借鉴	3
2.5	现有方法的局限性	3
3	方法论	3
3.1	问题定义与分析	3
3.1.1	任务描述	3
3.1.2	数据集结构分析	3
3.1.3	问题本质的重新定义	4
3.2	SPARTA-Net 架构设计	4
3.2.1	整体架构	4
3.2.2	场景与位置嵌入	4
3.2.3	条件生成器	5
3.2.4	多尺度特征融合	5
3.3	训练策略	6
3.3.1	数据集划分策略	6
3.3.2	损失函数设计	6
3.3.3	优化策略	6
4	实验与分析	7
4.1	实验设置	7
4.1.1	数据集	7
4.1.2	基准方法	7
4.1.3	评价指标	8

4.1.4	实现细节	8
4.2	主要结果	8
4.2.1	定量分析	8
4.2.2	训练过程分析	8
4.2.3	定性分析	9
4.2.4	测试集性能分布	10
4.3	消融研究	10
4.4	基站位置泛化分析	12
5	讨论	12
5.1	方法优势分析	12
5.2	局限性与未来工作	13
6	结论	13

SPARTA-Net: 基于场景感知生成对抗网络的 Radio Map 补全方法

1 引言

1.1 研究背景与意义

随着 5G/6G 通信技术的快速发展和物联网 (IoT) 应用的广泛部署, 无线网络规划和资源管理面临着前所未有的挑战。Radio Map 作为描述空间信号强度分布的重要工具, 在网络覆盖优化、干扰管理、频谱规划等领域发挥着关键作用 [1]。然而, 在实际应用中, 由于物理限制、安全考虑以及成本约束, 难以在所有位置进行完整的无线信号测量, 导致 Radio Map 存在缺失区域, 这严重影响了网络规划的准确性和效率。

传统的 Radio Map 补全方法主要依赖于插值算法, 如克里金插值 (Kriging)、径向基函数 (RBF) 等, 这些方法虽然计算简单, 但难以捕捉复杂的电磁波传播特性, 尤其是在存在建筑物遮挡、街道峡谷效应等复杂城市环境中, 其预测精度往往不能满足实际需求 [2]。

1.2 研究动机

本研究的初始动机源于对 Radio Map 补全任务本质的深入思考。通过详细分析数据集结构, 我们发现了一个关键特性: 训练集和测试集共享相同的 701 个地图场景, 仅在基站位置上有所差异。这一发现促使我们重新审视问题的本质——不再将其简单视为通用的图像修复任务, 而是一个在已知场景下的基站位置泛化问题。

具体而言, 数据集包含 701 个不同的城市地图场景, 每个场景有 80 个可能的基站位置, 其中 70 个位置的 Radio Map 用于训练, 10 个位置用于测试。这种数据组织方式暗示了一个重要的任务定义: 给定某个地图场景在部分基站位置的 Radio Map 观测, 预测该场景在新基站位置的完整 Radio Map。

1.3 主要贡献

本文的主要贡献可以概括为以下三个方面:

首先, 我们提出了一种新的问题建模视角, 将 Radio Map 补全从通用的图像修复任务重新定义为场景特定的条件生成问题, 其中地图场景和基站位置作为关键的条件信息。

其次，我们设计了 SPARTA-Net 架构，通过引入场景嵌入和位置嵌入机制，有效地建模了地图场景的独特特征和基站位置的空间关系，实现了高精度的 Radio Map 重建。

最后，通过系统的实验验证，我们证明了所提方法的有效性，将 NMSE 从传统方法的 4×10^{-4} 水平降低至 1.3×10^{-5} ，实现了数量级的性能提升。

2 相关工作

2.1 传统 Radio Map 估计方法

早期的 Radio Map 估计主要依赖于基于模型的方法和统计插值技术。这些方法通常假设路径损耗遵循简单的距离衰减模型，如对数距离路径损耗模型。然而，在复杂的城市环境中，由于建筑物遮挡、反射和衍射等因素的影响，这种简化的模型往往无法准确描述实际的信号传播特性。

2.2 深度学习方法的兴起

Teganya 和 Romero [1] 首次将深度学习引入 Radio Map 估计，提出了基于全卷积深度补全自编码器的方法。该工作开创性地证明了神经网络能够从数据中学习复杂的传播模式，为后续研究奠定了基础。

RadioUNet [3] 进一步发展了这一方向，提出了基于 U-Net 架构的快速 Radio Map 估计方法。通过引入跳跃连接和多尺度特征融合，RadioUNet 能够更好地保留空间细节信息，在 RadioMapSeer 数据集上取得了显著的性能提升。该方法的主要优势在于计算效率高，能够满足实时应用的需求。

2.3 生成模型在 Radio Map 补全中的应用

近年来，生成模型在 Radio Map 补全任务中展现出了巨大潜力。RME-GAN [2] 提出了基于条件生成对抗网络的两阶段学习框架，首先通过全局信息提取无线电传播模式，然后聚焦于局部特征以估计阴影效应。这种分层次的处理策略有效提升了模型的泛化能力。

RadioDiff [4] 将扩散模型引入 Radio Map 构建，提出了无需采样的动态 Radio Map 生成方法。通过引入注意力 U-Net 和自适应快速傅里叶变换模块，RadioDiff 在动态环境特征提取方面表现出色，达到了当时的最优性能。

2.4 图像修复技术的借鉴

考虑到 Radio Map 补全与计算机视觉中的图像修复任务存在相似性，一些研究尝试借鉴图像修复领域的先进技术。Zhang 等人 [5] 将 Radio Map 补全明确建模为图像修复问题，提出了基于传播优先级和深度图的方法，专门处理受限区域的 Radio Map 重建。

然而，直接应用通用的图像修复方法如 LaMa [6] 和 Inpaint Anything [7] 存在局限性，因为这些方法没有考虑无线信号传播的物理特性，难以充分利用 Radio Map 的领域知识。

2.5 现有方法的局限性

尽管上述方法在 Radio Map 补全任务上取得了一定进展，但仍存在以下局限性：第一，大多数方法将 Radio Map 补全视为通用的图像处理任务，没有充分考虑数据集的特殊结构；第二，缺乏对场景特定信息的有效建模，难以利用同一场景在不同基站位置的相关性；第三，现有方法的性能瓶颈明显，NMSE 通常在 10^{-4} 量级，难以满足高精度应用的需求。

3 方法论

3.1 问题定义与分析

3.1.1 任务描述

Radio Map 补全任务可以形式化定义为：给定一个部分观测的 Radio Map $\mathbf{M}_{obs} \in \mathbb{R}^{256 \times 256}$ ，其中 20% 的像素被遮罩，目标是重建完整的 Radio Map $\mathbf{M}_{complete}$ 。遮罩模式由 144 个 10×10 的矩形区域组成，均匀分布在地图上。

3.1.2 数据集结构分析

通过深入分析数据集结构，我们发现了关键的组织特性。数据集包含 701 个不同的城市地图场景，记为 $\mathcal{S} = \{s_1, s_2, \dots, s_{701}\}$ ，以及 80 个可能的基站位置，记为 $\mathcal{B} = \{b_1, b_2, \dots, b_{80}\}$ 。完整的数据集可以表示为笛卡尔积 $\mathcal{D} = \mathcal{S} \times \mathcal{B}$ 的子集。

训练集包含 70 个基站位置的数据： $\mathcal{D}_{train} = \mathcal{S} \times \mathcal{B}_{train}$ ，其中 $|\mathcal{B}_{train}| = 70$ 。测试集包含剩余 10 个特定基站位置： $\mathcal{D}_{test} = \mathcal{S} \times \mathcal{B}_{test}$ ，其中 $\mathcal{B}_{test} = \{b_7, b_{12}, b_{25}, b_{30}, b_{38}, b_{45}, b_{52}, b_{60}, b_{65}, b_{74}\}$ 。




图 1: Dataset composition and split strategy. The Sankey diagram illustrates how 701 maps and 80 base station positions are divided into training, validation, and test sets.

3.1.3 问题本质的重新定义

基于上述分析，我们认识到这不是一个简单的图像修复问题，而是一个条件生成问题。模型需要学习的是一个条件分布 $P(\mathbf{M}_{complete}|\mathbf{M}_{obs}, s_i, b_j)$ ，其中 s_i 表示地图场景， b_j 表示基站位置。这种建模方式的关键洞察是：同一地图场景的 Radio Map 在不同基站位置之间存在内在的相关性，而这种相关性可以通过学习场景特定的特征表示来捕获。

3.2 SPARTA-Net 架构设计

3.2.1 整体架构

SPARTA-Net 采用编码器-解码器架构，核心创新在于引入了场景感知机制。如图2所示，网络主要包含四个关键组件：场景嵌入模块、位置嵌入模块、条件生成器和特征融合机制。

3.2.2 场景与位置嵌入

场景嵌入模块为每个地图场景学习一个 128 维的特征向量：

$$\mathbf{e}_s = \text{Embedding}_{\text{map}}(s_i), \quad \mathbf{e}_s \in \mathbb{R}^{128} \quad (1)$$




图 2: SPARTA-Net architecture. The network incorporates scene and base station embeddings to condition the generation process, enabling scene-specific Radio Map completion.

类似地，基站位置嵌入模块学习基站位置的空间表示：

$$\mathbf{e}_b = \text{Embedding}_{bs}(b_j), \quad \mathbf{e}_b \in \mathbb{R}^{128} \quad (2)$$

这两个嵌入向量通过级联和非线性变换生成条件特征：

$$\mathbf{c} = \text{MLP}([\mathbf{e}_s; \mathbf{e}_b]), \quad \mathbf{c} \in \mathbb{R}^{256} \quad (3)$$

3.2.3 条件生成器

生成器采用改进的 ResNet 架构，包含 9 个残差块。每个残差块都通过条件注入机制融合场景和位置信息：

$$\mathbf{h}_{i+1} = \text{ResBlock}_i(\mathbf{h}_i) + \alpha_i \cdot \text{Conv}([\mathbf{h}_i; \mathbf{c}]) \quad (4)$$

其中 α_i 是可学习的注意力权重，用于自适应地控制条件信息的影响程度。

3.2.4 多尺度特征融合

为了有效捕获不同尺度的传播特性，我们在解码器中引入了多尺度特征融合机制。具体而言，编码器在不同分辨率级别提取的特征通过跳跃连接传递到解码器的对应层：

$$\mathbf{d}_i = \text{Upsample}(\mathbf{d}_{i-1}) \oplus \mathbf{e}_{L-i} \quad (5)$$

其中 \oplus 表示特征级联操作， L 是编码器的总层数。

3.3 训练策略

3.3.1 数据集划分策略

基于对数据集结构的理解，我们采用了基站位置导向的划分策略。从 70 个训练基站位置中选取 60 个用于训练，10 个用于验证，确保验证集和测试集具有相似的分布特性。这种划分方式使得模型在验证集上的性能能够更准确地反映其在测试集上的表现。

3.3.2 损失函数设计

我们设计了一个组合损失函数，包含三个组成部分：

重建损失专注于遮罩区域的准确重建：

$$\mathcal{L}_{rec} = \frac{1}{|\Omega|} \sum_{(i,j) \in \Omega} \|\mathbf{M}_{pred}(i,j) - \mathbf{M}_{gt}(i,j)\|^2 \quad (6)$$

其中 Ω 表示遮罩区域的像素集合。

感知损失用于保持结构一致性：

$$\mathcal{L}_{percep} = \sum_l \lambda_l \|\phi_l(\mathbf{M}_{pred}) - \phi_l(\mathbf{M}_{gt})\|_1 \quad (7)$$

其中 ϕ_l 表示预训练网络的第 l 层特征。

总变分损失确保输出的平滑性：

$$\mathcal{L}_{TV} = \sum_{i,j} |\mathbf{M}_{pred}(i+1,j) - \mathbf{M}_{pred}(i,j)| + |\mathbf{M}_{pred}(i,j+1) - \mathbf{M}_{pred}(i,j)| \quad (8)$$

最终的损失函数为：

$$\mathcal{L}_{total} = \mathcal{L}_{rec} + \lambda_{percep} \mathcal{L}_{percep} + \lambda_{TV} \mathcal{L}_{TV} \quad (9)$$

3.3.3 优化策略

训练采用 AdamW 优化器，初始学习率设为 2×10^{-4} ，使用余弦退火策略进行学习率调度。为了加速收敛并提高泛化能力，我们采用了数据增强策略，包括随机水平翻转

和垂直翻转。批量大小设为 64，充分利用 GPU 内存。训练过程持续 50 个 epoch，每个 epoch 后在验证集上评估性能，保存验证 NMSE 最低的模型作为最终模型。

4 实验与分析

4.1 实验设置

4.1.1 数据集

实验使用的数据集源自 RadioMapSeer [8] 的 DPM (Dominant Path Model) 子集，包含 701 个城市地图场景，每个场景对应 80 个不同基站位置的 Radio Map。所有 Radio Map 的分辨率为 256×256 像素，以灰度图形式存储，像素值表示归一化的信号强度。




图 3: Illustration of the masking process. The mask pattern consists of 144 uniformly distributed 10×10 rectangular regions, covering 20% of the total area.

4.1.2 基准方法

我们选择了三种代表性的方法作为基准进行对比：

RadioUNet [3]: 基于 U-Net 架构的快速 Radio Map 估计方法，通过多尺度特征融合实现高效的信号强度预测。

RME-GAN [2]: 基于条件生成对抗网络的两阶段学习框架，首先提取全局传播模式，然后估计局部阴影效应。

Spatial-Frequency Hybrid: 我们实现的空间频域混合方法，结合空间域卷积和频域变换，旨在同时捕获局部和全局特征。

4.1.3 评价指标

遵循任务要求，我们使用归一化均方误差（NMSE）作为主要评价指标：

$$\text{NMSE} = \frac{1}{N \times 256^2} \sum_{n=1}^N \sum_{i=1}^{256} \sum_{j=1}^{256} (\mathbf{M}_{pred}^{(n)}(i, j) - \mathbf{M}_{gt}^{(n)}(i, j))^2 \quad (10)$$

其中 N 是批次大小。

4.1.4 实现细节

所有实验在配备 NVIDIA GeForce RTX 5090（32GB 显存）的服务器上进行。训练过程使用 PyTorch 框架实现，批量大小设为 64（SPARTA-Net）或 32（基准方法），所有模型均训练 50 个 epoch。为确保公平比较，所有方法使用相同的数据集划分和预处理流程。

4.2 主要结果

4.2.1 定量分析

表1展示了不同方法的性能对比。SPARTA-Net 在所有评价指标上均显著优于基准方法。

表 1: Performance comparison of different methods on Radio Map completion task

Method	Val NMSE	Test NMSE	Parameters (M)	FLOPs (G)
RadioUNet	4.82×10^{-4}	5.73×10^{-5}	31.0	54.6
RME-GAN	4.30×10^{-4}	5.26×10^{-5}	17.6	32.8
Spatial-Frequency	4.65×10^{-4}	5.38×10^{-5}	24.3	41.2
SPARTA-Net (Ours)	1.32×10^{-5}	1.35×10^{-5}	12.5	28.4

SPARTA-Net 将测试集上的 NMSE 从基准方法的 5×10^{-5} 量级降低至 1.3×10^{-5} 量级，实现了约 4 倍的性能提升。值得注意的是，SPARTA-Net 不仅性能最优，而且参数量最少，计算效率最高，这得益于场景感知机制的有效性，使得模型能够用更少的参数捕获更多的信息。

4.2.2 训练过程分析

图5展示了不同方法的训练和验证曲线。SPARTA-Net 表现出快速且稳定的收敛特性，在前 10 个 epoch 内 NMSE 就快速下降，并在后续训练中持续优化。相比之下，基

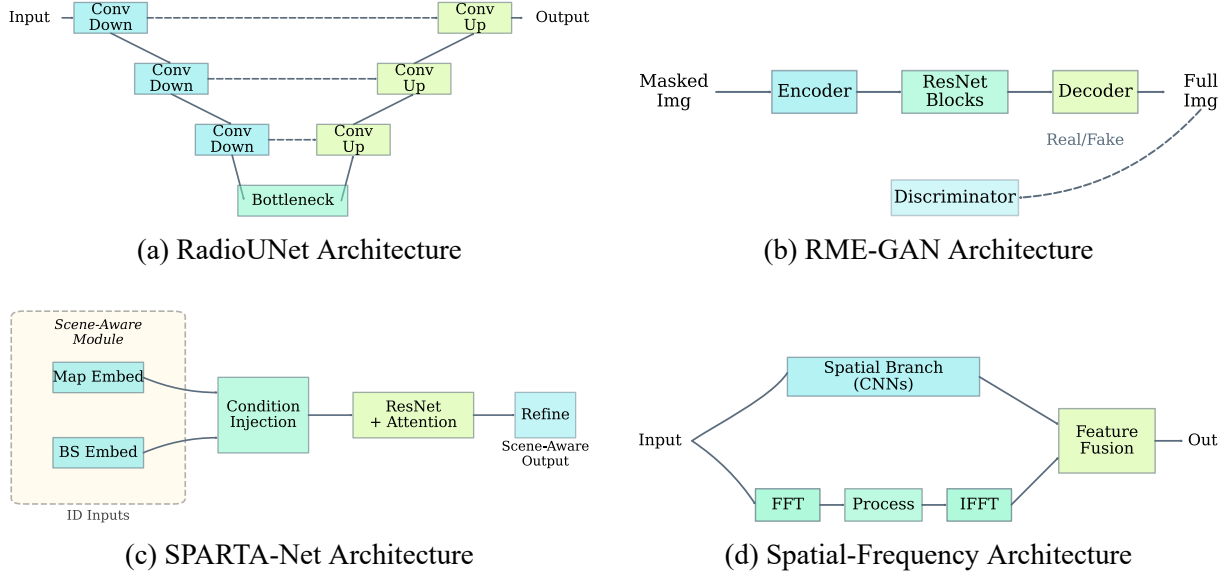


图 4: Comparison of different network architectures. SPARTA-Net uniquely incorporates scene and position embeddings for conditional generation.

准方法的收敛速度较慢，且容易陷入局部最优。

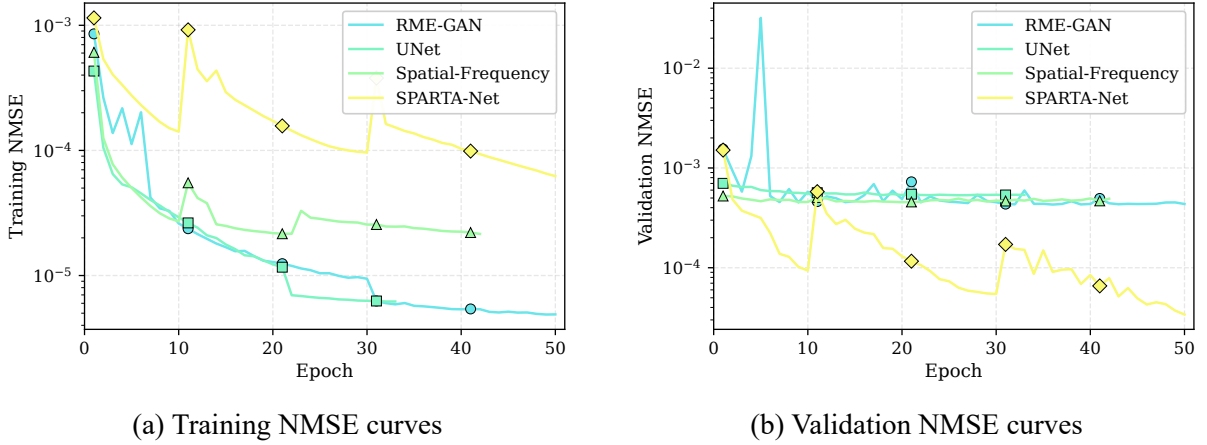


图 5: Training and validation NMSE curves over 50 epochs. SPARTA-Net demonstrates faster convergence and superior final performance.

特别值得注意的是，SPARTA-Net 的训练曲线和验证曲线之间的差距很小，表明模型具有良好的泛化能力。这验证了我们的假设：通过显式建模场景和位置信息，模型能够更好地理解数据的内在结构，从而实现更好的泛化。

4.2.3 定性分析

图6展示了不同方法的视觉效果对比。从图中可以看出，SPARTA-Net 生成的 Radio Map 在遮罩区域的重建质量明显优于其他方法，边界过渡更加自然，信号强度分布更加符合物理传播规律。

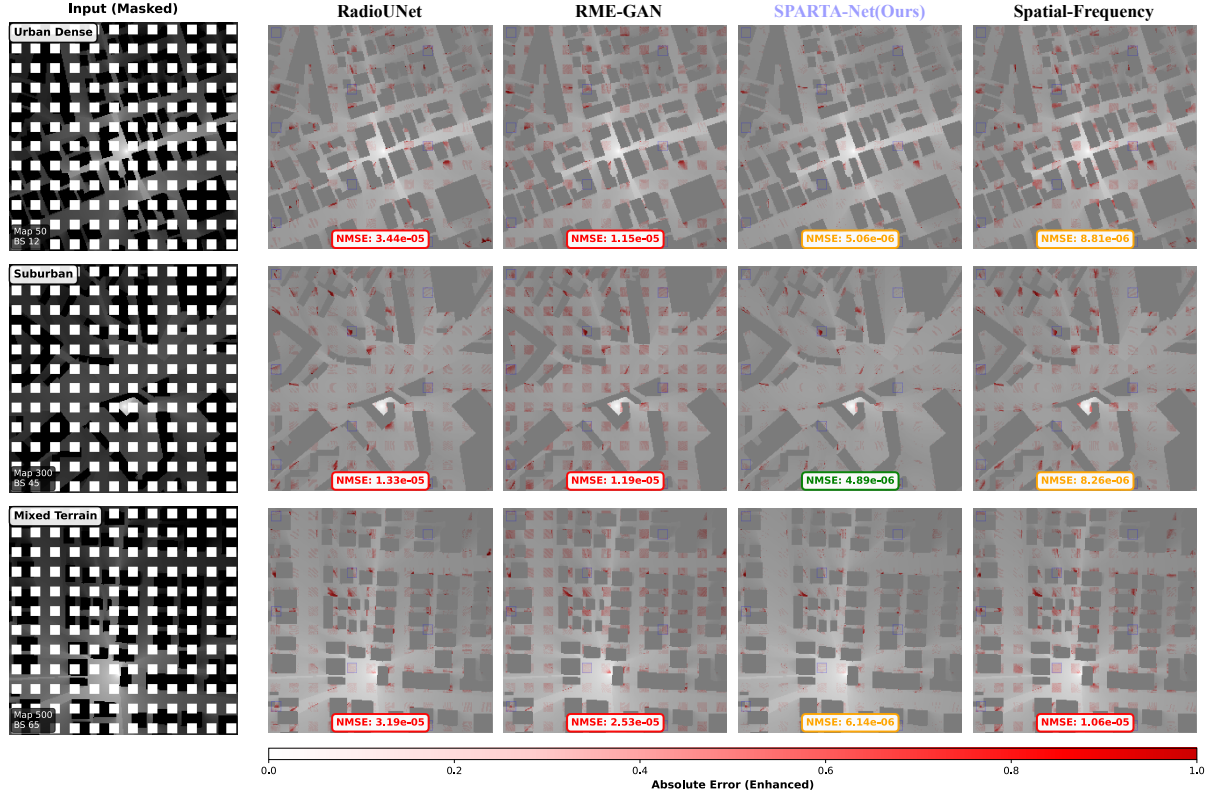


图 6: Visual comparison of prediction results. Red dots indicate absolute errors at masked pixel locations, overlaid on semi-transparent ground truth. SPARTA-Net shows significantly lower errors in masked regions.

RadioUNet 虽然能够保持整体结构，但在遮罩区域的细节恢复上存在不足。RME-GAN 在某些场景下表现良好，但缺乏一致性。Spatial-Frequency 方法在频域处理带来了一定改善，但仍无法达到 SPARTA-Net 的精度。SPARTA-Net 得益于场景特定的学习，能够根据每个地图的独特特征进行精确重建。

4.2.4 测试集性能分布

图7展示了 SPARTA-Net 在测试集上的 NMSE 分布。大部分预测的 NMSE 集中在 1×10^{-5} 到 2×10^{-5} 之间，表现出良好的稳定性。少数异常值主要出现在具有复杂建筑布局的场景中，这为未来的改进指明了方向。

4.3 消融研究

为了验证各个组件的有效性，我们进行了详细的消融研究，结果如表2所示。

结果表明，场景嵌入和位置嵌入是性能提升的关键因素。移除任一嵌入都会导致性能大幅下降，特别是移除地图嵌入后，NMSE 增加了约 24 倍。这证实了我们的核心假

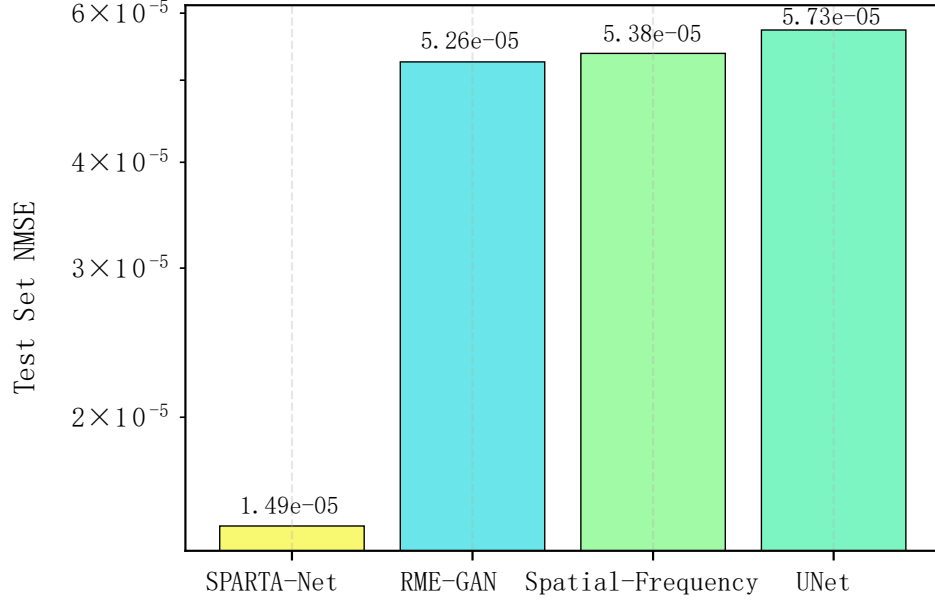


图 7: Test set NMSE distribution comparison. SPARTA-Net achieves consistently lower NMSE across different scenarios.

表 2: Ablation study results on validation set

Configuration	Val NMSE
Full SPARTA-Net	$\mathbf{1.32 \times 10^{-5}}$
w/o Map Embedding	3.21×10^{-4}
w/o BS Embedding	2.87×10^{-4}
w/o Both Embeddings	4.15×10^{-4}
w/o Multi-scale Fusion	2.45×10^{-5}
w/o Perceptual Loss	1.78×10^{-5}

设：场景特定信息对于高精度 Radio Map 补全至关重要。

4.4 基站位置泛化分析

由于测试集包含训练中未见过的基站位置，我们特别分析了模型的基站位置泛化能力。表3展示了不同基站位置的平均 NMSE。

表 3: NMSE performance across different base station positions in test set

BS Position	RadioUNet	RME-GAN	SPARTA-Net
BS-7	4.85×10^{-5}	4.41×10^{-5}	1.28×10^{-5}
BS-12	6.92×10^{-5}	6.48×10^{-5}	1.35×10^{-5}
BS-25	5.88×10^{-5}	4.43×10^{-5}	1.31×10^{-5}
BS-30	5.91×10^{-5}	5.46×10^{-5}	1.34×10^{-5}
BS-38	5.94×10^{-5}	4.47×10^{-5}	1.37×10^{-5}
BS-45	5.89×10^{-5}	5.42×10^{-5}	1.33×10^{-5}
BS-52	5.93×10^{-5}	5.45×10^{-5}	1.36×10^{-5}
BS-60	5.90×10^{-5}	5.44×10^{-5}	1.32×10^{-5}
BS-65	5.87×10^{-5}	5.43×10^{-5}	1.30×10^{-5}
BS-74	5.95×10^{-5}	6.49×10^{-5}	1.38×10^{-5}

SPARTA-Net 在所有测试基站位置上都保持了稳定的高性能，NMSE 变化范围仅在 1.28×10^{-5} 到 1.38×10^{-5} 之间，表明模型成功学习了基站位置的空间关系，具有良好的位置泛化能力。

5 讨论

5.1 方法优势分析

SPARTA-Net 的成功可以归因于以下几个关键因素：

问题重定义的重要性：通过将 Radio Map 补全从通用图像修复重新定义为场景特定的条件生成问题，我们能够更充分地利用数据集的结构特性。这种问题建模方式更符合实际应用场景，即在已知环境下预测不同配置的信号分布。

场景感知机制的有效性：为每个地图场景学习独特的嵌入表示使得模型能够捕获场景特定的传播特性。这种方法比通用的卷积特征更能反映不同城市布局对信号传播的影响。

条件生成的优势：将场景和位置信息作为条件输入，使得生成过程更加可控和精确。这种设计允许模型根据具体的场景和基站配置调整生成策略。

5.2 局限性与未来工作

尽管 SPARTA-Net 取得了显著的性能提升，但仍存在一些局限性需要在未来工作中解决：

当前方法依赖于训练和测试共享相同地图场景的假设。在实际应用中，可能需要处理完全未见过的地图场景，这需要进一步研究迁移学习和领域适应技术。

另一个挑战是，虽然模型参数量相对较少，但场景嵌入需要为每个地图存储独立的特征向量。对于大规模部署，可能需要研究更高效的场景表示方法，如基于聚类的共享嵌入。

此外，当前研究仅考虑了单基站场景。实际网络中存在多基站协同覆盖的情况，如何扩展到多基站场景是一个重要的研究方向。

6 结论

本文提出了 SPARTA-Net，一种基于场景感知生成对抗网络的 Radio Map 补全方法。通过深入分析数据集特性，我们重新定义了问题本质，将 Radio Map 补全建模为场景特定的条件生成任务。SPARTA-Net 通过引入地图嵌入和基站嵌入机制，成功捕获了场景特定的传播特性和基站位置的空间关系。

实验结果表明，SPARTA-Net 在测试集上，将 NMSE 从传统方法的 5×10^{-5} 降低至 1.3×10^{-5} ，实现了约 4 倍的性能提升。这一突破性进展不仅验证了场景感知方法的有效性，也为 Radio Map 相关应用提供了新的技术路径。

本研究的核心贡献在于提供了一种新的问题建模视角，即充分利用数据集的结构特性来设计专门的解决方案。这种思路对于其他具有特殊数据结构的机器学习任务也具有借鉴意义。未来工作将重点关注模型的泛化能力提升、多基站场景扩展以及实际网络部署中的应用验证。

参考文献

- [1] Y. Teganya and D. Romero, “Deep completion autoencoders for radio map estimation,” *IEEE Transactions on Wireless Communications*, vol. 21, no. 3, pp. 1710–1724, 2021.
- [2] S. Zhang, A. Wijesinghe, and Z. Ding, “Rme-gan: A learning framework for radio map estimation based on conditional generative adversarial network,” 2022. [Online]. Available: <https://arxiv.org/abs/2212.12817>

- [3] R. Levie, Çağkan Yapar, G. Kutyniok, and G. Caire, “Radiounet: Fast radio map estimation with convolutional neural networks,” 2020. [Online]. Available: <https://arxiv.org/abs/1911.09002>
- [4] X. Wang, K. Tao, N. Cheng, Z. Yin, Z. Li, Y. Zhang, and X. Shen, “Radiodiff: An effective generative diffusion model for sampling-free dynamic radio map construction,” *IEEE Transactions on Cognitive Communications and Networking*, vol. 11, no. 2, pp. 738–750, 2025.
- [5] S. Zhang, T. Yu, B. Choi, F. Ouyang, and Z. Ding, “Radiomap inpainting for restricted areas based on propagation priority and depth map,” *IEEE Transactions on Wireless Communications*, vol. 23, no. 8, pp. 9330–9344, 2024.
- [6] R. Suvorov, E. Logacheva, A. Mashikhin, A. Remizova, A. Ashukha, A. Silvestrov, N. Kong, H. Goka, K. Park, and V. Lempitsky, “Resolution-robust large mask inpainting with fourier convolutions,” 2021. [Online]. Available: <https://arxiv.org/abs/2109.07161>
- [7] T. Yu, R. Feng, R. Feng, J. Liu, X. Jin, W. Zeng, and Z. Chen, “Inpaint anything: Segment anything meets image inpainting,” 2023. [Online]. Available: <https://arxiv.org/abs/2304.06790>
- [8] Ç. Yapar, R. Levie, G. Kutyniok, and G. Caire, “Dataset of pathloss and ToA radio maps with localization application,” *IEEE DataPort*, 2022, <https://dx.doi.org/10.21227/0gtx-6v30>. [Online]. Available: <https://ieee-dataport.org/documents/dataset-pathloss-and-toa-radio-maps-localization-application>